

Chapter 5 文献转算法验收报告

版本：2026-09-30 | 交付对象：算法专家代码验收

1. 交付范围

本目录把 Yi Ma 等人的 Deep Representation Learning Book Chapter 5 中与 CRATE、MSSA/ISTA、TSSA/ToST 和 causal CRATE 相关的明确公式，转成 NumPy/float64 reference。它是可审计的算法原型，不是训练好的 CRATE 模型，也不是随机分析或全局收敛证明。随机分析主线 01_geometry、02_spectral、03_generative 没有被修改。

2. 原始文献与逐项对应

主要来源：Chapter 5
<https://ma-lab-berkeley.github.io/deep-representation-learning-book/Ch5.html>；Chapter 5 TeX <https://raw.githubusercontent.com/Ma-Lab-Berkeley/deep-representation-learning-book/main/chapters/chapter5/deep-networks.tex>；官方 CRATE <https://github.com/Ma-Lab-Berkeley/CRATE>；White-Box Transformers <https://arxiv.org/abs/2311.13110>。

文献对象	公式/思想	当前实现	边界
coding rate	(5.2.2), (5.2.3)	coding_rate / subspace_coding_rate	数值计算
exact gradient	(5.2.9)	exact_coding_rate_gradient	不声称可扩展训练
Neumann	(5.2.10)-(5.2.12)	neumann_gradient + 余项	要求 $ A < 1$
SSA/MSSA	(5.2.14)-(5.2.15)	mssa	softmax kernel 不等同 Neumann 截断
CRATE layer	(5.2.20)-(5.2.22)	crate_layer	architecture-level Z+MSSA
ISTA	(5.2.21)	ista	nonnegative=True 对应 ReLU
TSSA	(5.3.16)-(5.3.18)	tssa	未做 ToST 训练
causal CRATE	(5.3.19)-(5.3.30)	mask + projected cache	NumPy correctness reference
Example 5.4	loop 研究方向	looped_crate	无新增收敛定理

3. 核心接口与状态

接口：mssa(Z,U,epsilon,kappa,mask=None)、ista(H,D,eta,lambd_,nonnegative=False)、crate_layer(Z,layer_config,mask=None)、looped_crate(X,run_spec)。receipt 包含 run_id、source/config hash、seed、task、R、dtype/device、预算、状态、停止原因、coding-rate、sparsity、SNR、范数、operator residual、wall time、memory、FLOPs、compile time 和 diagnostics。

状态固定为 SOURCE_READ、SOURCE_SPECIFIED、OPERATOR_IMPL、SYNTHETIC_CONDITIONAL、CONDITIONAL_APPROX、DERIVED_PROTOTYPE、PASS、FAIL_CLOSED、UPSTREAM_BLOCKED、UNKNOWN、NOT_RUN、NOT_EVALUATED、STALE。

4. R0-R3 验证

R0：来源已登记；Example 5.4 保留为研究方向。官方 CRATE 远程 commit 当前因本机网络代理不可达而无法 pin，记录为 REMOTE_COMMIT_UNAVAILABLE_NETWORK_BLOCKED。

R1：float64，rtol=1e-8、atol=1e-10。覆盖 slogdet、exact gradient、Neumann 余项、MSSA softmax、ISTA、CRATE、TSSA/dense、causal cache、非法输入和 receipt schema。源码目录外运行时 14 项测试通过。

R2：d=128、K=4、p=32、N=128、tau=0.75、eta=0.1，delta={0.05,0.10,0.20}，开发 seed={0,1,2}，审计 seed={10,11,12}。数据为低秩子空间联合空间中的 Gaussian toy，包含非正交、重尾和错误 U 负对照；状态为 SYNTHETIC_CONDITIONAL。

R3：causal full-mask 与 projected-cache incremental reference 逐元素一致；complexity 覆盖 N={128,256,512,1024,2048} 的 MSSA/TSSA/dense wall time、tracemalloc 峰值和 analytic FLOPs estimate；loop 覆盖 6 seed、R={1,2,4,8}、parameter-matched no-loop 和 equal-FLOPs untied baseline。

观测对象	log-log wall-time 斜率	解释
MSSA	约 2.30	本机 float64 reference 观察
TSSA	约 0.63	本机 float64 reference 观察
dense attention	约 1.97	本机 float64 reference 观察

5. 代码审计重点

1) mssa 的 softmax 是行归一化后转置聚合，测试验证行和为 1。2) ista(nonnegative=True) 才对应文献 ReLU/nonnegative LASSO；默认 False 是显式的一般 soft-threshold 选项。3) causal_mssa_incremental 使用 projected cache，但仍是 NumPy correctness reference。4) tssa 不构造 N×N token similarity 矩阵，但未完成 ToST 训练或真实任务评估。5) looped_crate 是 Example 5.4 的 derived prototype；局部 coding-rate、ISTA surrogate 或 SNR 变化不等于任务误差下降、全局收敛或随机分析定理。

6. 验收结论

代码和证据可交给算法专家复核：算子实现为 OPERATOR_IMPL；定理 toy 为 SYNTHETIC_CONDITIONAL；causal/复杂度为 CONDITIONAL_APPROX；loop 为 DERIVED_PROTOTYPE；真实任务收益、生产级 KV cache 和远程 source commit pin 为 NOT_EVALUATED 或 UPSTREAM_BLOCKED。新的原始论文或差异应先更新 source_manifest.json，再修改代码、测试、hash 和 round evidence。